

IF5153 Natural Language Processing
Laporan Praktikum 1

Disusun untuk memenuhi tugas mata kuliah Pemrosesan Bahasa Alami
pada Semester 1 (satu) Tahun Akademik 2025/2026
Tugas Besar IF5153 Pemrosesan Bahasa Alami



Oleh

Shabrina Maharani

13522134

**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
BANDUNG
2025**

I. Penjelasan Kombinasi Tools

Pada tahap ini, saya mencoba melakukan dua kombinasi yang berbeda untuk abstrak yang berjudul “SemEval2024–Task10: Emotion Discovery and Reasoning its Flip in Conversation (EDiReF)”. Berikut adalah penjelasan dari kedua kombinasi tersebut.

Kombinasi 1

Kombinasi pertama menggunakan beberapa tahap menggunakan kombinasi dari beberapa tools:

1. Lemmatization & Tokenization

Pada tahap ini, teks dipecah menjadi token-token kemudian diubah ke bentuk dasar dengan *lemmatization*. Tujuannya supaya kata-kata yang berbeda bentuk tetapi punya makna yang sama bisa disatukan dan analisis bisa lebih fokus ke inti dari makna kata sehingga hasil analisis lebih konsisten, misalnya *tasks* akan dikategorikan sebagai *task*.

2. POS Tagging (NOUN, VERB, ADJ, PROPN)

Analisis kelas dari suatu kata menggunakan POS tagger digunakan untuk memfilter hanya kata benda, kata kerja, kata sifat, dan proper noun karena kategori ini paling relevan dalam merepresentasikan topik, domain, atau istilah penting dalam dokumen. Dengan mengetahui dan jadi bisa membatasi kategori, hasil analisis menjadi lebih fokus dan dapat mengabaikan kata-kata yang kurang bermakna seperti konjungsi atau determinan.

3. Bigram Tokenization Extraction (Co-occurrence)

Langkah ini digunakan untuk menemukan pasangan kata yang sering muncul bersama, misalnya *code-mix* atau *emotion flip*. Bigram membantu mengenali istilah teknis yang tidak dapat ditangkap jika hanya menganalisis per satu kata. Dengan menggunakan bigram, makna yang lebih spesifik bisa lebih terlihat.

4. Noun Phrase Chunking

Selain bigram, sistem juga bisa mencari frasa benda yang lebih panjang seperti *code-mixed dialogues* atau *emotion flip reasoning*. Frasa ini biasanya menjadi istilah

domain yang lebih bermakna dan memberikan informasi konteks yang lebih baik daripada hanya per satu kata.

5. **Filtering dengan Seed Words (Domain, Subtask, Dataset)**

Untuk memastikan hasil tetap relevan, dapat dilakukan dengan menyaring kata yang mengandung *keyword* yang telah ditentukan, seperti *dialogue*, *subtask*, atau *dataset*. Cara ini membuat analisis lebih terarah dan sesuai dengan kebutuhan.

Dari hasil insight yang didapatkan, kombinasi ini lebih cocok untuk menentukan kata kunci utama, istilah domain, dan ringkasan subtask dan dataset.

Kombinasi 2

Kombinasi kedua dilakukan dengan menggunakan kombinasi yang berbeda untuk analisis yang lebih dalam:

1. **Named Entity Recognition (NER)**

Kombinasi ini diawali dengan mendeteksi (entity detection sama seperti yang dilakukan saat entity masking) entitas bernama seperti organisasi, bahasa, angka, atau orang. NER digunakan untuk mendapatkan informasi faktual secara eksplisit, contohnya SemEval-2024 Task 10 atau skor evaluasi 0.70, 0.79, 0.76.

2. **Phrase Chunking**

Tahap ini membantu menampilkan konsep-konsep yang relevan, misalnya monolingual English and Hindi-English code-mixed dialogues, jadi topik utama lebih terlihat.

3. **Keyword Frequency**

Penghitungan frekuensi kata penting dengan metode tokenisasi dan lemmatization. Dengan menggunakan tahap ini, kata dominan seperti emotion atau task bisa diidentifikasi sebagai topik inti.

4. **Syntactic Parsing (SVO Extraction)**

Tahap terakhir adalah mencari struktur kalimat untuk menemukan hubungan subjek–predikat–objek. Misalnya relasi systems → attain → scores. Dengan parsing ini,

analisis tidak hanya menemukan istilah, tetapi juga bisa memahami peran atau aksi yang terjadi dalam sebuah teks.

Dari hasil yang didapatkan, kombinasi ini lebih berguna apabila kita ingin mengetahui makna semantik seperti: siapa melakukan apa, entitas apa yang terlibat, dan konsep apa saja yang muncul.

II. Kelebihan dan Kelemahan Masing-Masing Kombinasi

Kombinasi 1 kelebihanannya adalah lebih sederhana dan cepat. Pendekatan ini bisa menangkap kata kunci utama, istilah dalam domain, dan istilah penting dengan cara yang ringkas. Analisis ini cocok digunakan ketika tujuan utama kita adalah merangkum topik dan menemukan istilah penting tanpa terlalu banyak detail tambahan.

Kelemahan dari kombinasi 1 adalah keterbatasan untuk mencari hubungan semantik dan informasi faktual. Kombinasi I lebih berfokus pada frekuensi kata dan frasa, jadi analisis ini cenderung menghasilkan kata-kata yang umum seperti task atau system yang tidak terlalu informatif. Selain itu, tanpa NER, detail spesifik seperti nama organisasi atau skor evaluasi tidak dimasukkan ke dalam insight.

Kombinasi 2 lebih baik dalam memberikan gambaran atau dalam membantu memahami makna semantik dari sebuah teks. Dengan menggunakan NER dan syntactic parsing, analisis bisa menampilkan entitas spesifik, aksi utama, dan frasa panjang yang memperjelas konteks. Hasilnya lebih mendalam dan semantik, sehingga cocok untuk pemahaman relasional.

Kelemahan dari kombinasi 2 adalah kompleksitasnya lebih tinggi. Hasil analisis bisa terlalu detail jadi kurang ringkas. Selain itu, metode ini juga membutuhkan komputasi yang lebih besar dibandingkan Kombinasi 1.

III. Kelebihan dan Kelemahan Metode SpaCY

1. Sentence Splitter

Kelebihannya bisa memecah teks panjang menjadi kalimat-kalimat sehingga analisis lebih terstruktur. Kelemahannya bisa kesalahan ketika terdapat tanda baca yang ambigu atau teks dengan bahasa campuran.

2. Tokenization

Tokenization memecah kalimat menjadi unit kata atau token, jadi memudahkan analisis. Kelemahannya, tokenisasi seringkali salah pada bahasa campuran, singkatan, atau kata yang tidak baku.

3. Stemming

Kelebihannya adalah mengurangi kata ke bentuk dasar dengan cepat, membuat analisis lebih sederhana. Kelemahannya, stemming sering menghasilkan bentuk kata yang tidak alami dan kadang membingungkan.

4. Lemmatization

Kelebihannya lebih akurat dibanding stemming. Kekurangannya adalah membutuhkan sumber daya lebih besar dan tetap bisa salah jika kata ambigu.

5. Entity Masking

Kelebihan teknik ini adalah bisa menjaga kerahasiaan data dan bisa lebih fokus pada struktur teks tanpa dipengaruhi entitas tertentu. Kelemahannya adalah kehilangan detail yang bisa jadi penting untuk analisis.

6. POS Tagger

POS tagging membantu mengidentifikasi kelas kata sehingga analisis bisa fokus pada kategori penting. Kekurangannya adalah ketergantungan pada akurasi model dan kesalahan tagging bisa mengganggu hasil analisis.

7. Phrase Chunking

Kelebihannya bisa menangkap frasa benda atau struktur frasa yang lebih informatif daripada satu kata. Kelemahannya, bisa menghasilkan frasa yang terlalu umum atau redundan sehingga tidak menambah wawasan baru.

8. Syntactic Parse

Parsing sintaksis dapat mencari hubungan antar kata dalam bentuk struktur kalimat, misalnya relasi subjek–predikat–objek. Kekurangannya adalah hasil parsing sering tidak stabil pada kalimat panjang atau kompleks, dan kadang interpretasinya bisa membingungkan.

IV. Alternatif

Alternatif yang lebih baik untuk memahami konteks suatu kalimat adalah dengan menggunakan pendekatan yang lebih berfokus pada makna semantik. Misalnya, dependency parsing dan semantic role labeling (SRL) dapat membantu menjelaskan hubungan subjek–predikat–objek sehingga terlihat siapa melakukan apa terhadap siapa. Teknik ini bisa dilengkapi dengan transformer-based embeddings seperti BERT atau RoBERTa yang bisa memahami makna kata sesuai konteks kalimat. Selain itu, coreference resolution juga bisa digunakan untuk menghubungkan kata ganti dengan entitas yang dirujuk dalam teks, dikombinasikan dengan discourse analysis yang bisa memperlihatkan hubungan antar kalimat, seperti elaborasi, kontras, atau sebab–akibat. Hasil ekstraksi ini juga dapat diproyeksikan ke dalam knowledge graph supaya entitas dan relasi yang muncul lebih jelas secara struktural.

V. Kesimpulan

Dari analisis, Kombinasi 1 lebih tepat digunakan untuk ringkasan cepat yang berfokus untuk mencari kata kunci utama dan istilah domain, sementara Kombinasi 2 lebih berguna ketika tujuan analisis adalah memahami konteks semantik, entitas, dan hubungan antar elemen dalam teks. Seluruh tools spaCY yang digunakan memiliki fungsi saling melengkapi, mulai dari level kata hingga struktur kalimat. Oleh karena itu, pendekatan terbaik sebenarnya adalah menggabungkan elemen-elemen dari kedua kombinasi agar hasil analisis tetap ringkas tetapi tetap detail.