

IF5153 Natural Language Processing
Laporan Praktikum 4
Text Classification using Transfer Learning

Disusun untuk memenuhi tugas mata kuliah Pemrosesan Bahasa Alami
pada Semester 1 (satu) Tahun Akademik 2025/2026
Tugas Besar IF5153 Pemrosesan Bahasa Alami



Oleh

Shabrina Maharani

13522134

**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
BANDUNG
2025**

I. Deskripsi Persoalan

Text classification adalah salah satu task dalam bidang Natural Language Processing (NLP) yang bertujuan untuk mengelompokkan teks ke dalam kategori tertentu berdasarkan isi atau maknanya. Salah satu penerapannya adalah analisis sentimen, yaitu mengidentifikasi apakah suatu teks mengandung opini positif atau negatif.

Pada praktikum kali ini, mahasiswa diminta untuk membangun sistem klasifikasi teks sentimen dengan menggunakan pendekatan transfer learning. Tahapan yang dilakukan meliputi EDA sederhana untuk memahami karakteristik data, preprocessing data untuk menyiapkan teks dan label agar sesuai dengan format pemrosesan model, serta menggunakan tokenizer dari model pretrained yang mengubah teks menjadi representasi numerik (token ID dan attention mask) yang dapat diproses oleh model.

Model klasifikasi yang digunakan adalah beberapa algoritma transfer deep learning, seperti BERT, RoBERTa, XLM-RoBERTa, DistilBERT, dan ALBERT. Tujuan akhirnya adalah menganalisis hasil tokenisasi dengan melihat bagaimana masing-masing tokenizer memecah teks menjadi token-token berbeda, serta membandingkan performa dari setiap model transfer learning dalam melakukan klasifikasi sentimen berdasarkan metrik seperti accuracy dan F1-score.

II. Penjelasan EDA dan Preprocessing

Tahap Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik data sebelum model transfer learning dilatih. Visualisasi distribusi label menunjukkan bahwa dataset bersifat imbalanced, di mana jumlah data pada kelas negatif jauh lebih banyak dibandingkan kelas positif. Ketidakseimbangan ini dapat mempengaruhi performa model karena model biasanya lebih baik dalam mengenali kelas yang mayoritas.

Selanjutnya, dilakukan analisis panjang teks baik dalam satuan kata maupun karakter. Dari hasil histogram, sebagian besar teks memiliki panjang antara 40 hingga 120 kata, dengan beberapa teks yang lebih panjang namun tidak terlalu ekstrem. Hal ini menunjukkan bahwa data yang digunakan relatif seragam dan cocok untuk diproses oleh model transformer yang memiliki batas panjang token tertentu .

Selain itu, dilakukan juga analisis WordCloud untuk setiap label sentimen. Visualisasi ini membantu mengidentifikasi kata-kata yang paling sering muncul dalam teks positif dan negatif. Pada kelas positif, kata-kata seperti joy, loved, laughter, dan love lebih dominan. Pada kelas negatif, kata-kata seperti new, life, dream, dan feeling sering muncul.

Dari hasil WordCloud tersebut, terlihat bahwa kata-kata bernada emosional menjadi penentu utama dalam klasifikasi sentimen. Analisis ini juga membantu memahami konteks semantik yang nantinya akan dipelajari oleh model.

Selanjutnya, tahap preprocessing bertujuan untuk menyiapkan data agar dapat diproses oleh model deep learning. Langkah-langkah utama yang dilakukan meliputi:

1. Penyesuaian kolom

Nama kolom pada dataset diubah dari "Text" menjadi "text" dan dari "Sentiment" menjadi "label" agar sesuai dengan format umum pada pipeline NLP.

2. Pemetaan label

Kolom label yang semula berbentuk teks seperti "Positive" dan "Negative" diubah menjadi nilai numerik (1 dan 0) melalui dictionary mapping. Hal ini dilakukan agar model dapat mengenali label sebagai nilai target yang bisa dioptimasi secara matematis.

3. Pembersihan data kosong

Setelah pemetaan label, baris data yang memiliki nilai kosong (NaN) pada kolom label dihapus untuk menghindari error pada tahap pelatihan.

4. Konversi tipe data

Kolom label dikonversi menjadi tipe data int untuk memastikan keseragaman format saat data diubah menjadi dataset Hugging Face.

5. Pemisahan data latih dan uji

Dataset dibagi menjadi 80% data latih dan 20% data uji menggunakan stratified split agar proporsi label tetap seimbang di kedua subset. Hasil pembagian ini kemudian dikonversi menjadi format Dataset dari library HuggingFace Datasets, yang dapat langsung digunakan untuk proses tokenisasi dan pelatihan model.

Tahapan preprocessing ini memastikan data berada dalam kondisi siap pakai, terstruktur, bersih, dan konsisten sehingga proses tokenisasi dan embedding oleh model pretrained dapat berjalan optimal.

III. Analisis Tokenizer

Hasil tokenisasi dari kelima model menunjukkan adanya perbedaan dalam cara masing-masing tokenizer memecah teks menjadi potongan-potongan subword. Model BERT dan DistilBERT, yang menggunakan jenis tokenizer WordPiece, memecah kata menjadi unit-unit kecil berdasarkan frekuensi kemunculan dalam korpus pelatihannya. Misalnya, kata “Exploring” dipecah menjadi ["Ex", "##plor", "##ing"] dengan tanda ## menunjukkan bahwa token tersebut merupakan kelanjutan dari kata sebelumnya seperti gambar di bawah.

```
==== BERT (WordPiece) ====
Sentence: Exploring the world of digital art. It's never too late to discover new passions. #digitalartistry #latebloomer
Tokens: ['Ex', '##ploring', 'the', 'world', 'of', 'digital', 'art', '.', 'It', "'", 's', 'never', 'too', 'late', 'to', 'discover', 'new', 'passions', '##s', '.', 'e', 'Digital', '##a', '##ti', '##str', '##y', 'e', 'late', '##b', '##lo', '##oom', '##er']
```

```
==== DistilBERT (WordPiece) ====
Sentence: Exploring the world of digital art. It's never too late to discover new passions. #digitalartistry #latebloomer
Tokens: ['exploring', 'the', 'world', 'of', 'digital', 'art', '.', 'it', "'", 's', 'never', 'too', 'late', 'to', 'discover', 'new', 'passions', '.', 'e', 'digital', '##art', '##ist', '##ry', 'e', 'late', '##bl', '##oom', '##er']
```

Pendekatan ini menjaga keseimbangan antara ukuran kosakata yang kecil dan kemampuan menangani kata baru yang out-of-vocabulary. Hasilnya, WordPiece menghasilkan representasi yang detail dan informatif, tapi jumlah token yang terbentuk juga lebih banyak dibandingkan metode lain.

Tetapi, meskipun BERT dan DistilBERT sama-sama menggunakan WordPiece, hasil tokenisasinya berbeda. Hal ini disebabkan oleh perbedaan pada vocabulary, korpus pelatihan, dan pengaturan casing yang digunakan. BERT multilingual dilatih menggunakan data dari berbagai bahasa dan mempertahankan huruf kapital (cased), sehingga token seperti “Exploring” dapat terpecah menjadi beberapa subword seperti “Ex” dan “##ploring”. Sedangkan, DistilBERT bersifat uncased (semua huruf diubah menjadi huruf kecil) jadi kata “exploring” menjadi satu token penuh karena kata tersebut sering muncul dalam korpus pelatihan bahasa Inggrisnya. Jadi, meskipun menggunakan algoritma yang sama, konfigurasi dan korpus yang berbeda bisa menyebabkan perbedaan hasil tokenisasi antar model WordPiece.

Selanjutnya, pada RoBERTa yang menggunakan metode Byte-Pair Encoding (BPE), tokenisasi dilakukan dengan cara menggabungkan pasangan karakter yang paling sering muncul secara bertahap berdasarkan frekuensi dalam korpus pelatihan. Proses BPE melihat teks sebagai kumpulan karakter individual terlebih dahulu, kemudian secara iteratif menggabungkan pasangan karakter yang paling sering muncul menjadi unit subword baru. Misalnya, untuk kata “Exploring”, awalnya token dasarnya berupa ["E", "x", "p", "l", "o", "r", "i", "n", "g"]. Karena kombinasi karakter “Ex” sering muncul, maka BPE menggabungkannya menjadi ["Ex", "p", "l", "o", "r", "i", "n", "g"]. Selanjutnya, kombinasi “Expl” juga sering ditemukan, sehingga digabung lagi menjadi ["Expl", "o", "r", "i", "n", "g"], yang pada akhirnya terbentuk token final ["Expl", "oring"]. Dengan metode ini, sebuah kata tidak memerlukan simbol tambahan seperti pada metode WordPiece milik BERT yang biasanya menandai kelanjutan kata dengan simbol “##”.

```
==== ROBERTa (BPE) ====
Sentence: Exploring the world of digital art. It's never too late to discover new passions. #DigitalArtistry #Latebloomer
Tokens: ['Expl', 'oring', 'the', 'world', 'of', 'digital', 'art', '.', 's', 'never', 'too', 'late', 'to', 'discover', 'new', 'passions', '.', '@', 'Digital', 'Art', 'istry', '@', 'Late', 'bloom', 'er']
```

BPE menghasilkan tokenisasi yang lebih efisien karena panjang sekuens menjadi lebih pendek, sehingga proses pelatihan dan inferensi dapat berjalan lebih cepat sebagaimana dapat dilihat pada gambar di atas. Tetapi, metode ini kadang memotong kata tanpa memperhatikan struktur morfologisnya, sehingga hubungan semantik antar bagian kata dapat berkurang.

Sementara itu, model seperti **XLM-RoBERTa** dan **ALBERT** menggunakan **SentencePiece**, sebuah metode tokenisasi yang bersifat *unsupervised* dan berbasis probabilistik. SentencePiece tidak bergantung pada spasi, melainkan bekerja langsung pada teks asli untuk menentukan batas subword secara statistik.

```
==== XLM-RoBERTa (SentencePiece) ====
Sentence: Exploring the world of digital art. It's never too late to discover new passions. #DigitalArtistry #Latebloomer
Tokens: ['_Expl', '_ring', '_the', '_world', '_of', '_digital', '_art', '.', 's', 'never', '_too', '_late', '_to', '_discover', '_new', '_passion', 's', '.', '@', 'Digital', 'Arti', 'stry', '@', 'La', 'te', 'B', 'loom', 'er']
```

Hasilnya, kata “Exploring” dipecah menjadi ["_Expl", "or", "ing"], di mana simbol “_” (garis bawah blok) menandai sebuah kata dimulai. Metode ini lebih fleksibel karena mampu menangani berbagai bahasa, termasuk bahasa tanpa spasi seperti Jepang atau Korea, serta lebih adaptif terhadap variasi struktur kata.

Hal yang sama pada WordPiece juga terjadi pada SentencePiece, XLM-RoBERTa dan ALBERT sama-sama menggunakan SentencePiece, tapi hasil tokenisasi keduanya berbeda. Hal ini disebabkan oleh perbedaan ukuran kosakata, korpus pelatihan, serta domain data yang digunakan. XLM-RoBERTa dilatih menggunakan korpus multibahasa CommonCrawl, sedangkan ALBERT menggunakan Wikipedia dan BookCorpus bahasa Inggris. Oleh karena itu, kata seperti “Exploring” bisa muncul lebih sering di ALBERT sehingga dianggap sebagai satu token utuh, sementara di XLM-RoBERTa yang lebih beragam bahasanya, kata tersebut mungkin jarang muncul sehingga dipecah menjadi beberapa subword seperti ["_Explo", "ring"].

Tokenization Summary:					
	Model	Avg Tokens	Min Tokens	Max Tokens	Total Tokens (5 samples)
0	BERT (WordPiece)	25.6	7	42	128
1	RoBERTa (BPE)	22.4	8	37	112
2	XLM-RoBERTa (SentencePiece)	26.0	9	43	130
3	DistilBERT (WordPiece)	21.6	7	35	108
4	ALBERT (SentencePiece)	21.8	7	35	109

Dari segi panjang tokenisasi, metode WordPiece (BERT dan DistilBERT) cenderung menghasilkan jumlah token yang lebih banyak karena proses pemecahan yang lebih halus, sedangkan BPE (RoBERTa) menghasilkan token paling sedikit sehingga lebih efisien dalam segi waktu dan memori. SentencePiece berada di antara keduanya, tapi tokenisasi ini tetap menjaga struktur semantik kata. Dari jumlah-jumlah tersebut, model dengan tokenisasi efisien seperti RoBERTa biasanya lebih cepat dilatih, tetapi WordPiece biasanya tetap lebih baik dalam menangani teks multibahasa yang memiliki banyak variasi morfologis.

Selain itu, hasil tokenisasi juga memperlihatkan perbedaan dalam cara masing-masing tokenizer menangani kata yang langka dan karakter non-alfabetik seperti hashtag. WordPiece pada BERT dan DistilBERT, misalnya, memecah hashtag #WineTasting menjadi token ['#', 'Wine', '##Tas', '##ting'], sehingga model tetap dapat memahami konteks kata “wine” dan “tasting” secara terpisah. RoBERTa dengan BPE menandai spasi menggunakan simbol khusus “Ġ” untuk menunjukkan awal kata baru, seperti pada ['Ġ#', 'Wine', 'T', 'asting']. Sementara itu, SentencePiece yang digunakan oleh XLM-RoBERTa dan ALBERT menambahkan simbol garis

bawah “_” untuk menandai batas awal kata, misalnya ['#', '_Wine', 'Tas', 'ting']. Perbedaan strategi ini menunjukkan bahwa setiap tokenizer memiliki mekanisme sendiri dalam menangani teks sosial media yang kaya akan simbol dan format non-standar.

IV. Analisis Model Transfer Learning

1. Mekanisme dan Prinsip Kerja Model

Kelima model yang diuji pada praktikum kali ini diantaranya BERT, RoBERTa, XLM-RoBERTa, DistilBERT, dan ALBERT yang seluruhnya berbasis arsitektur Transformer encoder, yang menggunakan mekanisme self-attention untuk menangkap hubungan kontekstual antar token dalam sebuah kalimat. Transformer membuat setiap kata memperhatikan seluruh kata lain dalam kalimat secara paralel, sehingga konteks semantik dapat lebih dipahami oleh komputer.

1. BERT (Bidirectional Encoder Representations from Transformers)

BERT menggunakan pendekatan bidirectional dimana model membaca kalimat dari dua arah secara bersamaan dari kiri ke kanan dan kanan ke kiri. Proses pretraining-nya dilakukan dengan dua tugas utama yaitu Masked Language Modeling (MLM) dan Next Sentence Prediction (NSP). Dalam MLM, sebagian kata pada input di-*masking*, dan model dilatih untuk menebak kata yang hilang berdasarkan konteks sekitarnya. Pendekatan ini membuat BERT bisa memahami relasi antar kata secara lebih mendalam. BERT menggunakan WordPiece tokenizer, yang memecah kata menjadi subword seperti ["Ex", "##plor", "##ing"] yang bisa menjaga keseimbangan antara ukuran kosakata dengan fleksibilitas dalam menghadapi kata baru (out-of-vocabulary).

2. RoBERTa (A Robustly Optimized BERT Pretraining Approach)

RoBERTa merupakan penyempurnaan dari BERT dengan modifikasi pada proses pretraining. Model ini menghapus Next Sentence Prediction dan memperpanjang waktu pelatihan dengan ukuran batch serta volume data yang jauh lebih besar. Selain itu, RoBERTa juga menerapkan dynamic masking, yaitu pola kata yang disembunyikan berubah di setiap epoch, membuat model belajar lebih banyak konteks yang beragam. Tokenisasi pada RoBERTa dilakukan dengan menggunakan Byte-Pair Encoding (BPE).

Pendekatan ini menghasilkan representasi yang lebih efisien karena panjang sekuens yang lebih pendek dibanding WordPiece.

3. **XLM-RoBERTa (Cross-Lingual Language Model)**

XLM-RoBERTa memperluas konsep RoBERTa ke skenario multibahasa. Model ini dilatih menggunakan lebih dari 100 bahasa tanpa label (unsupervised multilingual pretraining), sehingga bisa membangun representasi semantik yang lintas bahasa. Tokenisasi menggunakan SentencePiece, yang tidak bergantung pada spasi, tapi diimplementasikan langsung pada teks asli untuk menentukan batas subword berdasarkan distribusi statistik.

4. **DistilBERT (Distilled BERT)**

DistilBERT merupakan versi ringan dari BERT yang dikembangkan menggunakan teknik knowledge distillation. Dalam pendekatan ini, super model nya yaitu model BERT mentransfer pengetahuannya ke model yang lebih kecil melalui soft target probabilities, bukan hanya hard labels. DistilBERT mempertahankan sekitar 97% performa BERT dengan 40% parameter yang lebih sedikit. Karena menggunakan arsitektur lebih sederhana dan tanpa Next Sentence Prediction, model ini lebih cepat dan efisien dalam pelatihan maupun inferensi.

5. **ALBERT (A Lite BERT)**

ALBERT dirancang untuk meningkatkan efisiensi memori dan kecepatan pelatihan tanpa mengurangi kompleksitas arsitektur. Model ini menggunakan dua teknik utama parameter sharing dan factorized embedding parameterization (memisahkan dimensi embedding dari dimensi hidden). Selain itu, ALBERT mengganti tugas NSP milik BERT dengan Sentence Order Prediction (SOP) yang menilai urutan logis antar kalimat. Seperti XLM-RoBERTa, ALBERT juga menggunakan tokenizer SentencePiece.

2. Analisis Hasil Eksperimen

Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Hasil keseluruhan dapat dilihat pada gambar berikut

7. Hasil Perbandingan

```
import pandas as pd
pd.DataFrame(results).T
```

	eval_loss	eval_accuracy	eval_f1	eval_precision	eval_recall	eval_runtime	eval_samples_per_second	eval_steps_per_second	epoch
bert-base-multilingual-cased	0.446104	0.932203	0.932203	0.932203	0.932203	9.5864	12.309	1.565	10.0
roberta-base	0.415194	0.940678	0.940025	0.939605	0.940678	8.2572	14.291	1.817	10.0
xlm-roberta-base	0.264738	0.940678	0.942392	0.945926	0.940678	9.9213	11.894	1.512	10.0
distilbert-base-uncased	0.306458	0.940678	0.938578	0.938746	0.940678	4.1775	28.246	3.591	10.0
albert-base-v2	0.335476	0.923729	0.922890	0.922269	0.923729	8.7872	13.429	1.707	10.0

Dari hasil tersebut, terlihat bahwa seluruh model memberikan performa tinggi setelah melakukan 10 epoch dengan accuracy di atas 92%, menunjukkan bahwa pendekatan transfer learning sangat efektif bahkan pada dataset berukuran relatif kecil. RoBERTa dan XLM-RoBERTa menjadi model dengan hasil terbaik secara konsisten, mencapai accuracy dan F1-score sekitar 0.94, dengan XLM-RoBERTa memiliki loss paling kecil (0.26) dan nilai F1-score tertinggi (0.942) karena memiliki kemampuan generalisasi yang kuat.

DistilBERT menunjukkan efisiensi waktu tertinggi dengan waktu evaluasi tercepat (eval_runtime 4.18 detik) tanpa kehilangan performanya dalam melatih data training. Model ini dapat menjadi alternatif ringan tapi dengan performa yang hampir setara. Model BERT walaupun sedikit lebih lambat dan memiliki loss yang lebih tinggi juga tetap memberikan hasil yang stabil karena kekuatan bidirectionalnya.

Terakhir, model ALBERT menunjukkan performa yang sedikit lebih rendah ($F1 = 0.9228$), tapi dengan efisiensi parameter yang jauh lebih baik, ini bisa jadi pilihan ideal untuk sistem dengan keterbatasan memori. Performa ini sejalan dengan desain arsitekturnya yang berfokus pada efisiensi dibanding akurasi maksimal.

V. Perbandingan Transfer Learning dengan Shallow ML dan Deep Learning

Pendekatan transfer learning berbasis Transformer menunjukkan peningkatan akurasi dan f1 score yang lebih baik dibandingkan model shallow dan deep learning konvensional. Model shallow seperti SVM, Logistic Regression, dan KNN hanya mengandalkan representasi statis seperti Bag-of-Words atau TF-IDF yang belum mampu memahami konteks semantik antar kata. Walaupun SVM sering menjadi baseline yang kuat tapi performanya tetap terbatas karena

representasi vektor nya yang sparse dan bersifat linear. Model deep learning seperti CNN, RNN, dan LSTM memang bisa menangkap urutan kata dan pola lokal, tapi tetap bergantung pada jumlah data yang harus besar dan masih kesulitan memahami konteks yang terlalu panjang ataupun hubungan antar kalimat yang cukup kompleks.

Untuk model transfer learning sendiri sudah melalui tahap pretraining pada korpus berskala besar menggunakan arsitektur Transformer. Proses ini membuat model jadi lebih memahami struktur sintaksis dan semantik bahasa sebelum dilakukan fine-tuning pada dataset sentimen. Hasil eksperimen menunjukkan bahwa model-model tersebut mencapai accuracy dan F1-score di atas 92%, melampaui performa model shallow dan deep learning sebelumnya yang umumnya berada di kisaran 85–89%. Selain akurasi yang tinggi, model Transformer juga memiliki kemampuan generalisasi yang kuat dan lebih adaptif terhadap variasi bahasa dan atau konteks.

Keunggulan performa dari transfer learning ini juga memiliki trade off yaitu kebutuhan komputasi yang lebih besar, baik dari sisi memori maupun waktu pelatihan. Model seperti BERT dan RoBERTa memiliki ratusan juta parameter yang memerlukan GPU berkapasitas tinggi, sementara model konvensional lebih ringan dan cepat dilatih pada perangkat dengan sumber daya komputasi yang terbatas.

VI. Kesimpulan

Berdasarkan hasil eksperimen yang telah dilakukan, dapat disimpulkan bahwa pendekatan transfer learning berbasis model Transformer memberikan peningkatan performa yang jauh lebih baik dibandingkan metode shallow dan deep learning konvensional dalam klasifikasi sentimen teks. Model seperti RoBERTa dan XLM-RoBERTa menunjukkan hasil terbaik dengan akurasi dan F1-score tertinggi di atas 93% yang artinya model-model tersebut menunjukkan kemampuan memahami konteks semantik yang sangat baik. Perbedaan mekanisme tokenisasi juga mempengaruhi hasil akhir. Secara keseluruhan, transfer learning terbukti menjadi pendekatan paling efektif untuk klasifikasi sentimen pada sebuah teks, meskipun membutuhkan sumber daya komputasi yang lebih tinggi dibandingkan model tradisional.