

IF5153 Natural Language Processing

Laporan Praktikum 5
Sequential Labeling

Disusun untuk memenuhi tugas mata kuliah Pemrosesan Bahasa Alami
pada Semester 1 (satu) Tahun Akademik 2025/2026
Tugas Besar IF5153 Pemrosesan Bahasa Alami



Oleh

Shabrina Maharani

13522134

PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
BANDUNG
2025

I. Deskripsi Persoalan

Sequential labeling merupakan salah satu task dalam bidang Natural Language Processing (NLP) yang bertujuan mengubah urutan teks tidak terstruktur menjadi format terstruktur, di mana setiap token (kata) diberi label yang merepresentasikan kategori tertentu. Salah satu penerapan paling umum adalah Named Entity Recognition (NER), yaitu proses mengidentifikasi dan mengklasifikasikan entitas penting seperti nama orang, organisasi, lokasi, dan lain-lain dari teks.

Pada praktikum ini, mahasiswa diminta untuk membangun sistem Named Entity Recognition (NER) dengan menggunakan berbagai pendekatan pembelajaran mesin dan transfer learning. Tahapan yang dilakukan meliputi tokenization untuk memecah teks menjadi token, preprocessing agar data sesuai dengan format pemrosesan model, serta pelabelan token menggunakan skema BIO (Begin, Inside, Outside) untuk menandai batas setiap entitas.

Eksperimen dilakukan menggunakan tiga teknik utama:

1. Teknik 1: Model machine learning sederhana (misalnya SVM atau Naive Bayes) dengan fitur yang diekstraksi secara berulang per token.
2. Teknik 2: Model deep learning (seperti CNN atau RNN) dengan berbagai jenis word embedding.
3. Teknik 3: Model pretrained language model (encoder-only Transformer) baik monolingual maupun multilingual, seperti ALBERT, DeBERTa, IndoBERT, dan XLM-RoBERTa.

Tujuan akhir dari praktikum ini adalah untuk menganalisis hasil pelabelan token serta membandingkan performa dari setiap pendekatan dalam melakukan Named Entity Recognition berdasarkan metrik evaluasi seperti accuracy dan F1-score.

II. Preprocessing

Tahap preprocessing dilakukan untuk menyiapkan data agar dapat digunakan dalam pelatihan model Named Entity Recognition (NER). Berbeda dengan klasifikasi teks yang menggunakan satu label per teks, pada NER setiap token dalam kalimat memiliki label tersendiri sesuai skema

BIO (Begin, Inside, Outside). Oleh karena itu, preprocessing difokuskan pada mapping antara token dan label agar format data sesuai dengan kebutuhan model sequential labeling.

Langkah pertama dilakukan dengan penyesuaian struktur data. Dataset awal yang terdiri dari kolom Sentence #, Word, dan Tag diubah agar setiap kalimat dikelompokkan ke dalam satu entri yang berisi daftar token serta daftar label yang sesuai. Proses ini dilakukan dengan mengelompokkan kata berdasarkan ID kalimat, sehingga setiap baris data mewakili satu urutan teks lengkap beserta label entitasnya.

Selanjutnya dilakukan pembersihan data untuk memastikan tidak ada nilai kosong pada kolom Word atau Tag. Baris yang mengandung nilai NaN dihapus guna mencegah error saat proses tokenisasi dan pembentukan tensor input.

Kemudian dilakukan pemetaan label menjadi indeks numerik. Setiap tag seperti B-PER, I-PER, B-ORG, I-ORG, dan O diberikan nilai indeks sesuai urutan yang ditentukan. Pemetaan ini penting agar label dapat diolah secara matematis oleh model deep learning.

Tahapan berikutnya adalah tokenisasi menggunakan tokenizer dari model pretrained (misalnya BERT, XLM-RoBERTa, atau IndoBERT). Tokenizer akan memecah setiap kata menjadi token subword yang sesuai dengan vocabulary model. Karena proses ini dapat membagi satu kata menjadi beberapa token, label asli juga disesuaikan: token pertama mewarisi label kata aslinya, sedangkan token-token berikutnya biasanya diberi label I- yang sama atau O tergantung strategi pelabelan yang digunakan.

Setelah proses tokenisasi selesai, dilakukan padding dan truncation agar setiap urutan token memiliki panjang yang seragam sesuai batas maksimal model (misalnya 128 atau 256 token). Attention mask juga dihasilkan untuk menandai posisi token yang valid dan posisi padding.

Terakhir, data yang telah ditokenisasi dikonversi menjadi format Dataset dari Hugging Face Datasets untuk memudahkan integrasi dengan pipeline pelatihan. Dataset kemudian dibagi menjadi data latih dan uji dengan proporsi tertentu (misalnya 80:20) untuk memastikan evaluasi model dapat dilakukan secara adil.

Tahapan preprocessing ini memastikan setiap token memiliki pasangan label yang tepat, format data konsisten, serta siap digunakan oleh model Transformer-based NER dalam proses fine-tuning dan evaluasi.

Proses penyesuaian label setelah tokenisasi dilakukan agar setiap token hasil pemecahan tokenizer memiliki label yang sesuai dengan kata asalnya. Karena tokenizer model Transformer (seperti BERT atau XLM-RoBERTa) dapat memecah satu kata menjadi beberapa token subword, maka diperlukan mekanisme untuk menyalin label dengan benar. Implementasinya dilakukan dengan memanfaatkan fungsi `word_ids()` dari tokenizer untuk melacak asal setiap token. Token pertama dari sebuah kata diberi label asli, sedangkan token-token hasil pecahan berikutnya dapat diberi label `I-` yang sama atau diatur menjadi `-100` agar diabaikan saat perhitungan loss. Pendekatan ini memastikan keselarasan antara input token dan target label, sehingga model dapat mempelajari konteks antar token tanpa kehilangan informasi entitas pada level kata.

III. Analisis Model

1. Mekanisme dan Prinsip Kerja Model

Enam model yang digunakan pada praktikum ini untuk menyelesaikan task Named Entity Recognition (NER) atau sequential labeling. Keenam model ini mewakili tiga pendekatan utama dalam pemrosesan bahasa alami: shallow machine learning, deep learning berbasis word embedding, dan transfer learning dengan pretrained language model berbasis Transformer encoder.

1. TF-IDF + SVM

Model ini merupakan pendekatan shallow machine learning yang sering digunakan sebagai baseline dan berdasarkan hasil praktikum sebelumnya, menunjukkan akurasi yang cukup baik. Dalam konteks NER, setiap kata pada kalimat diperlakukan sebagai satuan data (token-level classification), di mana representasi kata dibangun menggunakan Term Frequency–Inverse Document Frequency (TF-IDF). Nilai TF-IDF merepresentasikan seberapa penting sebuah kata dibandingkan kata lain dalam keseluruhan dataset. Representasi vektor dari setiap token kemudian dijadikan input

untuk Support Vector Machine (SVM), yang bertugas menemukan batas pemisah antar kelas label seperti B-PER, I-ORG, atau O. Dengan cara ini, SVM mencoba mengenali pola distribusi kata dan konteks sekitarnya secara statistik untuk memprediksi label entitas setiap token. Pendekatan ini memang tidak menangkap urutan atau hubungan antar kata secara langsung, karena setiap token diproses secara independen tanpa mempertimbangkan konteks kalimat penuh. Namun, kombinasi TF-IDF dan SVM biasanya efektif untuk dataset berukuran kecil dan memberikan hasil yang cepat serta stabil.

2. **Word2Vec + CNN**

Berbeda dengan TF-IDF yang hanya melihat frekuensi kata, Word2Vec mengubah setiap kata menjadi dense vector yang merepresentasikan makna dan hubungan semantik antar kata. Kata-kata dengan arti yang mirip akan memiliki posisi yang berdekatan di ruang vektornya. Hasil representasi ini kemudian menjadi input untuk Convolutional Neural Network (CNN), yang berfungsi mengenali pola urutan kata (n-gram) serta hubungan antar kata di sekitar token yang sedang diproses. Dalam task NER, CNN bekerja dengan melakukan scanning setiap bagian kalimat menggunakan sliding window untuk memahami konteks lokal di sekitar kata, lalu memprediksi label entity untuk setiap token berdasarkan pola tersebut. Pendekatan ini membuat model dapat mengenali entitas dengan melihat kata-kata di sekitarnya, misalnya, mengenali nama orang yang biasanya diikuti oleh jabatan atau kata kerja tertentu. Akan tetapi, CNN masih terbatas pada konteks lokal dan belum bisa memahami keseluruhan makna kalimat secara global seperti model berbasis Transformer.

3. **ALBERT (A Lite BERT)**

ALBERT merupakan salah satu model Transformer encoder yang fokus pada efisiensi parameter dan waktu pelatihan. Dalam NER, setiap token dalam kalimat diproses oleh ALBERT melalui mekanisme self-attention bidirectional, di mana setiap kata dapat memperhatikan semua kata lain di dalam kalimat. Hal ini memungkinkan model memahami konteks secara menyeluruh sebelum menentukan label untuk setiap token, misalnya membedakan apakah “Apple” merujuk pada perusahaan atau buah berdasarkan kata di sekitarnya. Efisiensi ALBERT diperoleh melalui dua teknik utama, yaitu

parameter sharing (berbagi bobot antar layer agar model lebih ringan) dan factorized embedding parameterization (memisahkan dimensi embedding dari dimensi hidden layer untuk menghemat memori). Dengan arsitektur ini, ALBERT tetap dapat melakukan pelabelan entitas dengan akurasi tinggi seperti BERT, tetapi dengan kebutuhan komputasi yang lebih rendah dan pelatihan yang lebih cepat.

4. **DeBERTa (Decoding-enhanced BERT with Disentangled Attention)**

DeBERTa juga merupakan pengembangan dari BERT yang dirancang untuk menangkap hubungan antar token dengan melalui mekanisme disentangled attention. Dalam task NER, pendekatan ini membuat DeBERTa dapat membedakan antara makna kata dan posisi token dalam kalimat secara lebih akurat. Misalnya, model dapat memahami bahwa kata “Bank” di posisi berbeda bisa merujuk pada lembaga keuangan atau tepi sungai tergantung konteks. DeBERTa juga menggunakan enhanced mask decoder yang memperkuat kemampuan model dalam memahami struktur kalimat kompleks dan memperjelas batas antar entitas. Dengan pemrosesan konteks yang lebih dalam dan representasi posisi yang lebih informatif, DeBERTa sering kali menghasilkan prediksi label entitas yang lebih presisi, terutama dalam kalimat panjang atau ambigu.

5. **IndoBERT**

IndoBERT merupakan model Transformer monolingual yang dilatih khusus untuk Bahasa Indonesia, sehingga memiliki pemahaman yang lebih baik terhadap struktur sintaksis dan morfologi bahasa ini. Dalam tugas NER, IndoBERT bekerja dengan cara mengonversi setiap token menjadi embedding lalu memprosesnya menggunakan lapisan self-attention bidirectional, yang memungkinkan setiap token mempertimbangkan konteks di seluruh kalimat sebelum diberi label entitas. Kelebihan ini membuat IndoBERT unggul dalam mengenali entitas khas Indonesia, seperti nama instansi pemerintah, tokoh nasional, atau tempat lokal, yang mungkin tidak dikenal oleh model multibahasa. Karena parameter dan kosakatanya dioptimalkan khusus untuk Bahasa Indonesia, model ini memberikan hasil yang lebih stabil dan relevan untuk teks berbahasa Indonesia dibandingkan model lintas bahasa.

6. **BERT-cased**

Setelah dilakukan analisis terhadap dataset, diketahui bahwa data pelatihan yang digunakan berbahasa Inggris. Oleh karena itu, digunakan model BERT-base-cased agar lebih sesuai dengan karakteristik bahasa pada data. Dalam konteks NER, BERT-cased berfungsi untuk mengenali label entitas setiap token dengan mempertimbangkan konteks dua arah melalui mekanisme self-attention. Model ini mempertahankan perbedaan huruf besar dan kecil (seperti “London” vs “london”), yang penting karena kapitalisasi sering menjadi penanda nama entitas dalam teks berbahasa Inggris. Tokenisasi dilakukan menggunakan WordPiece tokenizer, yang memecah kata menjadi potongan subword agar model dapat menangani kata baru (out-of-vocabulary). Sensitivitas terhadap huruf kapital dan pemahaman konteks global membuat BERT-cased efektif dalam mendeteksi entitas seperti nama orang, organisasi, atau tempat dengan presisi tinggi.

7. XLM-RoBERTa (Cross-Lingual Language Model)

XLM-RoBERTa merupakan model Transformer encoder multibahasa yang dilatih menggunakan lebih dari 100 bahasa. Dalam task NER, model ini memproses setiap token dalam berbagai bahasa dengan shared multilingual space sehingga dapat melakukan cross-lingual transfer, misalnya, pola yang dipelajari dari bahasa Inggris dapat membantu mengenali entitas dalam Bahasa Indonesia. Tokenisasi dilakukan menggunakan SentencePiece tokenizer, yang tidak bergantung pada spasi dan bekerja langsung pada teks mentah untuk menentukan batas subword. Pendekatan ini membuat model fleksibel dalam menangani berbagai struktur bahasa. Dalam praktiknya, XLM-RoBERTa mampu mengenali entitas lintas bahasa dengan baik, meskipun pada bahasa spesifik seperti Indonesia performanya sedikit lebih rendah dibanding model monolingual seperti IndoBERT. Namun, keunggulannya terletak pada kemampuan generalisasi tinggi dan keserbagunaan untuk berbagai bahasa dalam satu model.

Secara keseluruhan, perbedaan utama antar model terletak pada cara mereka merepresentasikan dan memahami konteks kata dalam kalimat. TF-IDF + SVM bergantung pada frekuensi kata tanpa memperhatikan urutan, Word2Vec + CNN menangkap konteks lokal antar token, sementara model Transformer seperti ALBERT, DeBERTa, IndoBERT, BERT-cased, dan XLM-RoBERTa memahami konteks secara global melalui mekanisme self-attention. Model

monolingual seperti IndoBERT dan BERT-cased unggul untuk bahasa tertentu karena pemahaman struktur linguistiknya lebih dalam, sedangkan model multibahasa seperti XLM-RoBERTa lebih fleksibel dalam menerapkan pengetahuan lintas bahasa.

2. Analisis Hasil Eksperimen

Evaluasi dilakukan menggunakan metrik *precision*, *recall*, dan *F1-score*. Hasil keseluruhan dapat dilihat pada gambar berikut

	precision	recall	f1-score	support
art	0.00	0.00	0.00	92
eve	0.16	0.10	0.12	42
geo	0.83	0.86	0.85	6167
gpe	0.94	0.90	0.92	1790
nat	0.10	0.04	0.06	24
org	0.66	0.66	0.66	3656
per	0.68	0.70	0.69	2782
tim	0.83	0.82	0.82	2229
micro avg	0.78	0.78	0.78	16782
macro avg	0.53	0.51	0.52	16782
weighted avg	0.77	0.78	0.78	16782

Gambar 1. Hasil Model Albert

	precision	recall	f1-score	support
art	0.00	0.00	0.00	92
eve	0.38	0.12	0.18	42
geo	0.82	0.88	0.85	6167
gpe	0.93	0.90	0.92	1790
nat	0.00	0.00	0.00	24
org	0.69	0.66	0.68	3656
per	0.70	0.72	0.71	2782
tim	0.83	0.83	0.83	2229
micro avg	0.79	0.79	0.79	16782
macro avg	0.55	0.51	0.52	16782
weighted avg	0.78	0.79	0.79	16782

Gambar 2, Hasil Model DeBERTa

	precision	recall	f1-score	support
art	0.10	0.08	0.09	92
eve	0.28	0.26	0.27	42
geo	0.85	0.88	0.87	6167
gpe	0.94	0.93	0.94	1790
nat	0.47	0.29	0.36	24
org	0.72	0.71	0.71	3656
per	0.75	0.78	0.76	2782
tim	0.85	0.84	0.84	2229
micro avg	0.81	0.82	0.81	16782
macro avg	0.62	0.59	0.60	16782
weighted avg	0.81	0.82	0.81	16782

Gambar 3. Hasil Model IndoBERT

	precision	recall	f1-score	support
art	0.00	0.00	0.00	92
eve	0.48	0.29	0.36	42
geo	0.84	0.89	0.87	6167
gpe	0.95	0.92	0.93	1790
nat	0.50	0.21	0.29	24
org	0.72	0.70	0.71	3656
per	0.73	0.75	0.74	2782
tim	0.82	0.83	0.83	2229
micro avg	0.80	0.81	0.81	16782
macro avg	0.63	0.57	0.59	16782
weighted avg	0.80	0.81	0.81	16782

Gambar 4. Hasil Model XLM-roBERTa

	precision	recall	f1-score	support
art	0.18	0.14	0.16	92
eve	0.33	0.33	0.33	42
geo	0.87	0.90	0.89	6167
gpe	0.95	0.94	0.95	1790
nat	0.33	0.29	0.31	24
org	0.77	0.74	0.75	3656
per	0.80	0.84	0.82	2782
tim	0.87	0.87	0.87	2229
micro avg	0.84	0.85	0.85	16782
macro avg	0.64	0.63	0.63	16782
weighted avg	0.84	0.85	0.84	16782

Gambar 5. Hasil Model BERT-cased

TF-IDF + SVM token-level results:		precision	recall	f1-score	support
B-art		0.0263	0.1522	0.0449	46
B-eve		0.0719	0.6286	0.1290	35
B-geo		0.7233	0.6769	0.6993	3797
B-gpe		0.9264	0.8781	0.9016	1592
B-nat		0.1230	0.7500	0.2113	20
B-org		0.4971	0.3723	0.4257	2055
B-per		0.6750	0.5318	0.5949	1668
B-tim		0.6995	0.7580	0.7276	2033
I-art		0.0049	0.0750	0.0091	40
I-eve		0.0395	0.5385	0.0736	39
I-geo		0.4738	0.5835	0.5229	713
I-gpe		0.1613	0.3125	0.2128	16
I-nat		0.0137	0.8571	0.0270	7
I-org		0.3617	0.3996	0.3798	1699
I-per		0.6638	0.5060	0.5743	1658
I-tim		0.2456	0.3846	0.2998	585
0		0.9534	0.9387	0.9460	88532
accuracy				0.8849	104535
macro avg		0.3918	0.5496	0.3988	104535
weighted avg		0.9031	0.8849	0.8930	104535

Gambar 6. Hasil Model SVM

CNN token-level results:				
	precision	recall	f1-score	support
B-art	0.1786	0.1111	0.1370	90
B-eve	0.2400	0.2308	0.2353	52
B-geo	0.5561	0.4301	0.4851	6684
B-gpe	0.7141	0.5195	0.6014	2876
B-nat	0.6000	0.2045	0.3051	44
B-org	0.5346	0.3485	0.4219	3616
B-per	0.5834	0.5432	0.5626	3008
B-tim	0.6270	0.5032	0.5583	3585
I-art	0.1579	0.0508	0.0769	59
I-eve	0.0952	0.0455	0.0615	44
I-geo	0.4737	0.4003	0.4339	1329
I-gpe	0.6364	0.3684	0.4667	38
I-nat	0.0000	0.0000	0.0000	12
I-org	0.5508	0.4311	0.4837	2992
I-per	0.5952	0.6275	0.6109	3060
I-tim	0.5861	0.2867	0.3851	1151
O	0.9277	0.9629	0.9449	155812
accuracy			0.8849	184452
macro avg	0.4739	0.3567	0.3983	184452
weighted avg	0.8735	0.8849	0.8773	184452

Gambar 7. Hasil Model CNN

Dari hasil tersebut, terlihat bahwa secara keseluruhan, model BERT-cased menunjukkan performa terbaik dan paling seimbang di antara seluruh model berbasis Transformer. Model IndoBERT dan XLM-RoBERTa juga menunjukkan hasil dengan selisih skor yang relatif kecil.

Sementara itu, model SVM dan CNN memiliki nilai weighted avg F1-score yang tinggi (masing-masing 0.89 dan 0.87), tapi angka tersebut bersifat menyesatkan karena hasil yang tinggi itu didapat karena didominasi oleh jumlah angka pada label “O” (kata-kata yang bukan entitas) yang jumlahnya jauh lebih banyak daripada label lain. Kalau hanya mempertimbangkan performa pada label entitas (B-tag dan I-tag) yang jumlahnya kecil, kedua model ini masih tertinggal jauh dari model berbasis transformer lainnya.

Model ALBERT dan DeBERTa menunjukkan performa paling rendah di antara kelompok Transformer, terutama karena keduanya gagal mendeteksi entitas dengan jumlah data yang sangat sedikit seperti art dan nat.

Berikut adalah tabel peringkat model berdasarkan macro avg f1-score nya:

Tabel 1. Peringkat Model

Peringkat	Model	Weighted AVG F1-Score	Macro AVG F1-Score	Analisis Singkat
1	BERT-cased	0.84	0.63	Paling seimbang dan konsisten di semua kategori entitas, termasuk yang langka seperti art dan nat.
2	IndoBERT	0.81	0.60	Model monolingual dengan performa tinggi pada entitas kelas mayoritas dan hasil stabil pada entitas minoritas.
3	XLM-RoBERTa	0.81	0.59	Setara dengan IndoBERT pada entitas besar, namun gagal total pada entitas art.
4	DeBERTa	0.79	0.52	Cukup kuat untuk entitas umum, tetapi tidak mampu mengenali entitas yang jumlahnya sedikit.
5	Albert	0.78	0.52	Efisien secara memori, namun kesulitan menangkap konteks pada entitas minoritas.
6	SVM	0.89	0.3988	Skor tinggi di Weighted F1-score karena dominasi label “O”; kinerja nyata yang dilihat dari Macro AVG pada entitas minoritas nilainya rendah.
7	CNN	0.87	0.3983	Sama seperti SVM, skor tinggi karena label mayoritas tapi tidak pada entitas minoritas,

Peringkat model pada analisis ini didasarkan pada nilai Macro Average F1-Score karena metrik ini memberikan gambaran yang lebih adil terhadap kemampuan model dalam mengenali setiap kelas entitas, terutama pada dataset yang tidak seimbang. Berbeda dengan weighted average yang cenderung bias terhadap label mayoritas (seperti label “O” pada tugas NER), macro average menghitung performa rata-rata dari semua label tanpa memperhitungkan proporsi datanya, sehingga lebih mencerminkan kemampuan model dalam mendeteksi entitas minoritas seperti art, nat, dan eve. Dalam proses pelatihan, model Transformer dikonfigurasi menggunakan parameter `num_train_epochs=7` dan `per_device_train_batch_size=8`, yang memungkinkan model belajar cukup lama untuk memahami konteks antar token, meskipun dengan risiko overfitting pada kelas mayoritas. Model SVM menggunakan `class_weight='balanced'` agar kesalahan pada kelas minoritas diberi bobot lebih besar, membantu model untuk tidak hanya berfokus pada label dominan. Sementara itu, pada model CNN, parameter `Embedding(trainable=True)` digunakan agar bobot embedding dapat diperbarui selama pelatihan sehingga model mampu menyesuaikan representasi kata terhadap pola yang relevan dengan entitas dalam data dan CNN juga dikonfigurasi menggunakan 7 epoch agar setara dengan transformer dan dapat dibandingkan.

A. Analisis berdasarkan Kelompok Model

1. Model Transformer (BERT-cased, IndoBERT, XLM-RoBERTa, DeBERTa, ALBERT)

BERT-cased menjadi model dengan performa paling unggul secara keseluruhan. Model ini mampu mencapai skor F1 yang stabil di hampir semua entitas, termasuk entitas minoritas seperti art (0.16) dan nat (0.31). BERT-cased dapat mengenali perbedaan huruf besar dan kecil sehingga membuat model ini lebih sensitif terhadap penanda entitas dalam teks berbahasa Inggris, seperti nama orang atau tempat yang biasanya diawali huruf kapital. Secara umum, BERT-cased menunjukkan keseimbangan terbaik antara akurasi tinggi pada entitas mayoritas maupun minoritas.

IndoBERT dan XLM-RoBERTa menempati posisi kedua dan ketiga dengan nilai weighted average F1 yang sama, yaitu 0.81. Keduanya cukup baik dalam mengenali entitas mayoritas seperti geo, gpe, org, dan per. Perbedaan utama antara keduanya terletak pada cakupan bahasa, IndoBERT adalah model monolingual yang dilatih khusus untuk Bahasa Indonesia, sedangkan

XLM-RoBERTa merupakan model multilingual yang mendukung lebih dari 100 bahasa. Dalam konteks ini, IndoBERT lebih unggul dalam memahami struktur dan gaya Bahasa Indonesia, sementara XLM-RoBERTa memiliki fleksibilitas lintas bahasa namun sedikit kehilangan ketepatan pada entitas spesifik. Hal ini terlihat dari kegagalannya mengenali entitas art, yang menunjukkan bahwa transfer antarbahasa belum sepenuhnya optimal untuk kategori dengan data yang sedikit. Akan tetapi, dataset pada praktikum ini berbahasa Inggris sehingga model BERT-based yang juga monolingual terhadap bahasa Inggris memiliki tingkat performa yang paling baik.

DeBERTa dan ALBERT sama-sama termasuk dalam kelompok model Transformer, namun memiliki fokus pengembangan yang berbeda. DeBERTa lebih berorientasi pada performance, dengan menambahkan mekanisme disentangled attention yang memisahkan informasi posisi dan konten token. Pendekatan ini membuat kedua model itu lebih kuat dalam memahami konteks kalimat panjang dan struktur yang kompleks. ALBERT dikembangkan dengan fokus pada efficiency, menggunakan teknik parameter sharing dan factorized embedding parameterization untuk menghemat memori dan mempercepat pelatihan tapi efisiensi ini memiliki konsekuensi yaitu performa ALBERT sedikit tertinggal, terutama pada entitas dengan jumlah data kecil. Kedua model ini masih cukup baik dalam mengenali entitas besar seperti geo dan gpe, tetapi kurang mampu menangkap entitas minoritas seperti art dan nat.

2. Model Klasik (SVM) dan Deep Learning Non-Transformer (CNN)

Model klasik seperti SVM menggunakan pendekatan berbasis fitur (TF-IDF), sedangkan CNN memanfaatkan representasi Word2Vec embedding. Kedua model ini mengalami kesulitan menangani konteks yang panjang dan bergantung pada pola lokal.

Pada model SVM, meskipun skor weighted avg tinggi, nilai tersebut didominasi oleh label “O” yang mendominasi dataset. Ketika hanya mempertimbangkan entitas (B- dan I- tags), performanya jauh menurun.

Pada model CNN dengan parameter trainable diubah menjadi True, model jadi bisa memperbarui bobot embedding selama proses pelatihan dan F1-score mencapai macro avg sebesar 0.3983.

CNN memiliki performa yang masih jauh di bawah model Transformer karena keterbatasan dalam menangkap konteks global dan hubungan antarkata dalam kalimat yang panjang.

B. Analisis berdasarkan Kategori Entitas

Kategori entitas dengan jumlah data yang mayoritas seperti geo, gpe, org, per, dan tim tergolong mudah dikenali oleh hampir semua model, terutama model berbasis Transformer. Pada kategori-kategori ini, sebagian besar model mampu mencapai F1-score yang tinggi, bahkan melebihi 0.90 untuk entitas gpe. Sebaliknya, entitas dengan jumlah data yang sangat sedikit seperti art, nat, dan eve masih sangat kecil F1-score nya. Hanya BERT-cased dan IndoBERT yang masih mampu menghasilkan nilai F1 di atas nol untuk kategori-kategori tersebut, sedangkan model lainnya gagal mengenali entitas dengan jumlah data rendah ini. Kondisi ini menunjukkan bahwa keterbatasan jumlah data latih berpengaruh besar terhadap kemampuan model dalam mengenali entitas minoritas, terutama bagi model yang tidak memiliki mekanisme pembelajaran kontekstual seperti BERT dan model model yang dikembangkan dari model tersebut.

IV. Kesimpulan dan Saran

Secara keseluruhan, BERT-cased menunjukkan performa paling unggul dan konsisten di semua kategori entitas, termasuk pada entitas yang jumlah datanya sangat sedikit seperti art dan nat. Model ini unggul karena model ini mempertahankan informasi kapitalisasi huruf yang penting dalam teks berbahasa Inggris serta memahami konteks antar kata secara dua arah. IndoBERT dan XLM-RoBERTa juga memberikan hasil yang baik pada entitas besar seperti geo, gpe, org, dan per, meskipun keduanya memiliki karakteristik berbeda IndoBERT lebih cocok untuk teks Bahasa Indonesia karena bersifat monolingual, sedangkan XLM-RoBERTa yang multibahasa lebih fleksibel namun sedikit menurun akurasi pada konteks bahasa tertentu. Di sisi lain, DeBERTa dan ALBERT menonjol dari segi efisiensi karena waktu latihnya lebih cepat dan penggunaan sumber daya lebih ringan, tetapi keduanya masih kesulitan mengenali entitas dengan data terbatas. Untuk model non-Transformer, SVM dan CNN menunjukkan nilai weighted average yang tinggi, tetapi hasil tersebut didominasi oleh label “O” (bukan entitas), sehingga tidak mencerminkan kemampuan sesungguhnya dalam mengenali entitas bernama. Setelah

embedding CNN dibuat trainable, performanya meningkat dengan F1-score rata-rata mencapai 0.3983, meskipun tetap belum sebanding dengan model Transformer. Berdasarkan hasil keseluruhan, BERT-cased direkomendasikan sebagai model terbaik untuk task NER pada dataset ini. Untuk meningkatkan hasil pada entitas dengan data kecil seperti art dan nat, disarankan menambah data latih atau menerapkan data augmentation, serta bisa juga menyesuaikan hyperparameter seperti memperbesar learning rate agar model dapat belajar lebih baik dari entitas yang jarang muncul.